

Optimización de un autoencoder lineal

Región de Confianza con iBFGS sobre el Hessiano inverso, memoria limitada y subproblema
Dogleg

Manuel McCadden Madrazo

ITAM — Análisis Aplicado I (MAT 24430)

Primavera 2026

13 de mayo de 2026

Resumen

Se construye un autoencoder lineal $\mathbb{R}^d \rightarrow \mathbb{R}^k \rightarrow \mathbb{R}^d$ y se entrena sin recurrir a diferenciación automática. El estado del modelo se ajusta minimizando la pérdida cuadrática mediante un método de *Región de Confianza*. Para evitar invertir matrices en cada iteración se mantiene directamente la *inversa aproximada del Hessiano* H_k (variante iBFGS) y se reformula el subproblema *Dogleg* de modo que el punto de Cauchy se obtenga por *interpolación cuadrática* de f a lo largo de $-\vec{g}_k$ (eliminando $\vec{g}_k^\top B_k \vec{g}_k$). Se compara la versión de matriz completa contra la de memoria limitada (L-BFGS, con recursión de dos ciclos) sobre un conjunto de valores $d \in \{3, 5, 10, 100\}$. Se reporta convergencia, tiempo, memoria persistente del estado del Hessiano y cercanía al óptimo global f^* , conocido en forma cerrada por el teorema de Eckart–Young.

Índice

1. Planteamiento del problema	2
1.1. Función objetivo	2
1.2. Gradiente analítico	2
1.3. Óptimo global de referencia	4
2. Estrategia: Región de Confianza	4
3. Algoritmos	5
3.1. Aproximación del Hessiano inverso: iBFGS	5
3.2. Subproblema: método Dogleg	5
3.3. Aproximación con memoria limitada: L-BFGS	8
3.4. Bucle externo	8
4. Resultados	9
4.1. Configuración experimental	9
4.2. Datos de entrada y reconstrucción para $d = 3$	9
4.3. Comportamiento del bucle externo	10
4.4. Escalamiento en d y comparativa BFGS / L-BFGS	11
4.5. Lectura de los resultados	11
5. Conclusiones	12

1. Planteamiento del problema

Dado un conjunto de N observaciones $X = [\vec{x}^{(1)}, \dots, \vec{x}^{(N)}] \in \mathbb{R}^{d \times N}$ con media nula, se busca un par de transformaciones lineales

$$E \in \mathbb{R}^{k \times d} \quad (\text{encoder}), \quad D \in \mathbb{R}^{d \times k} \quad (\text{decoder}), \quad (1)$$

con $k < d$, que minimicen el error de reconstrucción $\hat{X} = DEX$.

El estado del optimizador es el vector aplanado

$$\vec{x} := [\text{vec}(E); \text{vec}(D)] \in \mathbb{R}^n, \quad n = 2dk. \quad (2)$$

1.1. Función objetivo

Se minimiza el error cuadrático medio

$$f(\vec{x}) = \frac{1}{2N} \|DEX - X\|_F^2 \quad (3)$$

Sobre la norma de Frobenius. La norma de Frobenius admite la caracterización por columnas

$$\|A\|_F^2 = \sum_{i,j} A_{ij}^2 = \sum_{j=1}^N \|A_{:,j}\|_2^2, \quad (4)$$

de donde la pérdida (3) se reescribe como

$$f(\vec{x}) = \frac{1}{2N} \sum_{j=1}^N \|DEX^{(j)} - \vec{x}^{(j)}\|_2^2, \quad (5)$$

es decir, el promedio del error de reconstrucción euclideo al cuadrado por observación. La formulación en norma de Frobenius es por tanto equivalente al promedio del error cuadrático euclideo por muestra: hereda la diferenciabilidad de la norma euclidea, induce gradientes simétricos en D y E , y coincide con el criterio mínimo-cuadrático sobre el cual está construido el resultado de Eckart–Young que provee el óptimo global f^* (Sección 1.3).

1.2. Gradiente analítico

Sea $M := DEX - X \in \mathbb{R}^{d \times N}$ el residuo. Reescribiendo (3) entrada por entrada,

$$f = \frac{1}{2N} \sum_{i,j} M_{ij}^2, \quad (6)$$

de modo que cada gradiente parcial se obtiene por la regla de la cadena:

$$\frac{\partial f}{\partial D_{ab}} = \frac{1}{N} \sum_{i,j} M_{ij} \frac{\partial M_{ij}}{\partial D_{ab}}. \quad (7)$$

Todo el trabajo está en calcular $\partial M_{ij}/\partial D_{ab}$ (y luego $\partial M_{ij}/\partial E_{ab}$).

Derivada respecto a D . Expandiendo el producto matricial,

$$M_{ij} = \sum_{p=1}^k D_{ip} (EX)_{pj} - X_{ij}. \quad (8)$$

Al derivar respecto a una entrada concreta D_{ab} , todos los términos del sumatorio sobre p desaparecen excepto el único en el que aparece exactamente D_{ab} : el que tiene $i = a$ y $p = b$. Para los demás valores de i (digamos $i \neq a$) la expresión no contiene D_{ab} , por lo que su derivada es cero. Resultado:

$$\frac{\partial M_{ij}}{\partial D_{ab}} = \begin{cases} (EX)_{bj}, & \text{si } i = a, \\ 0, & \text{si } i \neq a. \end{cases} \quad (9)$$

Sustituyendo (9) en (7), los únicos términos que sobreviven son los de $i = a$:

$$\frac{\partial f}{\partial D_{ab}} = \frac{1}{N} \sum_{j=1}^N M_{aj} (EX)_{bj}. \quad (10)$$

La suma de la derecha es precisamente la entrada (a, b) del producto $M (EX)^\top$, ya que en general $(PQ^\top)_{ab} = \sum_j P_{aj} Q_{bj}$. Agrupando las entradas en una matriz se obtiene

$$\boxed{\nabla_D f(\vec{x}) = \frac{1}{N} M (EX)^\top \in \mathbb{R}^{d \times k}.} \quad (11)$$

Derivada respecto a E . Ahora E aparece dos niveles adentro:

$$M_{ij} = \sum_{p=1}^k \sum_{q=1}^d D_{ip} E_{pq} X_{qj} - X_{ij}. \quad (12)$$

Derivar respecto a E_{ab} selecciona el único término del doble sumatorio donde $p = a$ y $q = b$ (los factores D_{ip} y X_{qj} no contienen a E_{ab} , así que se quedan tal cual):

$$\frac{\partial M_{ij}}{\partial E_{ab}} = D_{ia} X_{bj}. \quad (13)$$

Sustituyendo en (7) (con E en lugar de D),

$$\frac{\partial f}{\partial E_{ab}} = \frac{1}{N} \sum_{i,j} M_{ij} D_{ia} X_{bj}. \quad (14)$$

Reordenando el sumatorio y reconociendo dos productos matriciales:

$$\frac{\partial f}{\partial E_{ab}} = \frac{1}{N} \sum_i D_{ia} \underbrace{\sum_j M_{ij} X_{bj}}_{(MX^\top)_{ib}} = \frac{1}{N} \sum_i \underbrace{D_{ia} (MX^\top)_{ib}}_{(D^\top M X^\top)_{ab}}, \quad (15)$$

de donde

$$\boxed{\nabla_E f(\vec{x}) = \frac{1}{N} D^\top M X^\top \in \mathbb{R}^{k \times d}.} \quad (16)$$

El gradiente total $\vec{g}_k := \nabla f(\vec{x}_k) \in \mathbb{R}^n$ se obtiene aplanando (11)–(16) en un único vector con la misma convención de empaquetado que $\vec{x}$. Las identidades matriz–índices empleadas son estándar; pueden consultarse en Petersen y Pedersen [3] o Magnus y Neudecker [4].

1.3. Óptimo global de referencia

El teorema de Eckart–Young establece que la mejor aproximación de X de rango k en norma de Frobenius está dada por la SVD truncada. Para la pérdida (3) esto implica

$$f^* = \frac{1}{2N} \sum_{i=k+1}^d \sigma_i^2, \quad (17)$$

donde $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_d \geq 0$ son los valores singulares de X . Cualquier algoritmo iterativo se evalúa por su cercanía a esta cota.

2. Estrategia: Región de Confianza

Se reemplaza la minimización directa de f por la minimización iterativa de un **modelo cuadrático local**

$$m_k(\vec{p}) := f(\vec{x}_k) + \vec{g}_k^\top \vec{p} + \frac{1}{2} \vec{p}^\top B_k \vec{p} \quad (18)$$

donde B_k representa una aproximación simétrica definida positiva del Hessiano $\nabla^2 f(\vec{x}_k)$. En la implementación se trabaja con la inversa aproximada $H_k := B_k^{-1}$, mantenida directamente por la actualización iBFGS descrita en la Sección 3.1; los algoritmos posteriores se formulan en términos de H_k .

En cada iteración se resuelve el **subproblema de región de confianza**:

$$\min_{\vec{p} \in \mathbb{R}^n} m_k(\vec{p}) \quad \text{sujeto a} \quad \|\vec{p}\|_2 \leq \Delta_k \quad (19)$$

con $\Delta_k > 0$ el *radio de confianza* en la iteración k . La aceptación o rechazo del paso resultante, así como la modificación de Δ_k , se basa en la razón

$$\rho_k = \frac{f(\vec{x}_k) - f(\vec{x}_k + \vec{p}_k)}{m_k(\vec{0}) - m_k(\vec{p}_k)} = \frac{\text{reducción real}}{\text{reducción predicha}}, \quad (20)$$

que mide qué tan bien m_k aproxima a f a lo largo del paso $\vec{p}_k$.

Estructura del método. Los tres elementos anteriores (modelo cuadrático, subproblema de región de confianza y razón ρ_k) se acomodan en un bucle iterativo. En cada iteración k :

1. Se evalúa el gradiente $\vec{g}_k = \nabla f(\vec{x}_k)$. La aproximación H_k del Hessiano inverso se hereda del paso anterior (la primera iteración usa $H_0 = I_n$). Juntos definen formalmente m_k , pero éste no se construye explícitamente: H_k se manipula solamente mediante productos $H_k \vec{v}$ (Sección 3.1).
2. Se resuelve aproximadamente el SPRC (19) para obtener un paso candidato $\vec{p}_k$ (Sección 3.2).
3. Se evalúa $f(\vec{x}_k + \vec{p}_k)$ y se calcula ρ_k .
4. Se ajusta el radio:
 - Si $\rho_k < \frac{1}{4}$: $\Delta_{k+1} = \frac{1}{4} \Delta_k$ (el modelo predijo peor de lo aceptable, se contrae la región).
 - Si $\rho_k > \frac{3}{4}$ y $\|\vec{p}_k\|_2 = \Delta_k$: $\Delta_{k+1} = \min(2\Delta_k, \Delta_{\text{máx}})$ (el modelo predijo bien y la frontera estaba activa, se expande).
 - En otro caso: $\Delta_{k+1} = \Delta_k$.

5. Se decide la aceptación: $\vec{x}_{k+1} = \vec{x}_k + \vec{p}_k$ si $\rho_k > \eta$, con $\eta \in [0, \frac{1}{4})$; $\vec{x}_{k+1} = \vec{x}_k$ en otro caso.
6. Si el paso se aceptó, se actualiza la aproximación del Hessiano con la nueva información de curvatura.

El radio se ajusta solo: cuando $\rho_k \approx 1$ el modelo aproxima fielmente a f en esa vecindad y conviene tomar pasos más largos; cuando ρ_k es chico o negativo el modelo es poco confiable y la región se contrae, forzando a la siguiente iteración a buscar dentro de un dominio más conservador. La Sección 3 desarrolla cada componente: la actualización del Hessiano aproximado (3.1), la resolución del subproblema (3.2), la variante de memoria limitada (3.3) y el bucle externo completo en pseudocódigo (3.4).

3. Algoritmos

3.1. Aproximación del Hessiano inverso: iBFGS

La actualización iBFGS produce, en cada iteración, una aproximación simétrica definida positiva H_k de $(\nabla^2 f(\vec{x}_k))^{-1}$. Definidos los incrementos

$$\vec{s}_k := \vec{x}_{k+1} - \vec{x}_k, \quad \vec{\gamma}_k := \nabla f(\vec{x}_{k+1}) - \nabla f(\vec{x}_k), \quad \rho_k := \frac{1}{\vec{\gamma}_k^\top \vec{s}_k}, \quad (21)$$

y bajo la condición de curvatura $\vec{s}_k^\top \vec{\gamma}_k > 0$:

$$\boxed{H_{k+1} = (I - \rho_k \vec{s}_k \vec{\gamma}_k^\top) H_k (I - \rho_k \vec{\gamma}_k \vec{s}_k^\top) + \rho_k \vec{s}_k \vec{s}_k^\top.} \quad (22)$$

La fórmula (22) preserva H_k simétrica definida positiva y satisface la ecuación de secante inversa $\vec{s}_k = H_{k+1} \vec{\gamma}_k$. Su costo es $O(n^2)$, dominado por dos productos externos.

Inicialización. Se toma $H_0 = I_n$, $\Delta_0 = 1$, $\Delta_{\text{máx}} = 10$, $\eta = 10^{-4}$.

3.2. Subproblema: método Dogleg

El subproblema (19) se resuelve aproximadamente con *Dogleg*, formulado en términos de productos $H_k \vec{v}$ y evaluaciones de f .

Paso de Newton. El minimizador no restringido de m_k es

$$\vec{p}_B = -B_k^{-1} \vec{g}_k = -H_k \vec{g}_k, \quad (23)$$

obtenido con un único producto matriz–vector de costo $O(n^2)$.

Punto de Cauchy por interpolación cuadrática. La fórmula clásica del Cauchy $\alpha_u = \vec{g}_k^\top \vec{g}_k / (\vec{g}_k^\top B_k \vec{g}_k)$ involucra una forma cuadrática con B_k . Como en cada iteración se mantiene H_k y no B_k , evaluar $\vec{g}_k^\top B_k \vec{g}_k$ exigiría invertir H_k explícitamente, con costo $O(n^3)$. Para evitar ese costo, se estima α_u ajustando una parábola a f a lo largo de la dirección $-\vec{g}_k$, usando únicamente evaluaciones de f y la información de gradiente que ya se tiene. Sea

$$\varphi(\alpha) := f(\vec{x}_k - \alpha \vec{g}_k), \quad \alpha \in \mathbb{R}. \quad (24)$$

Valor en cero: sustitución directa en (24)

$$\varphi(0) = f(\vec{x}_k - 0 \cdot \vec{g}_k) = f(\vec{x}_k) =: f_k. \quad (25)$$

Derivada en cero: aplicando la regla de la cadena a (24),

$$\varphi'(\alpha) = \left. \frac{d}{d\alpha} \right|_{\alpha} f(\vec{x}_k - \alpha \vec{g}_k) = (\nabla f(\vec{x}_k - \alpha \vec{g}_k))^{\top} (-\vec{g}_k), \quad (26)$$

y evaluando en $\alpha = 0$,

$$\varphi'(0) = (\nabla f(\vec{x}_k))^{\top} (-\vec{g}_k) = -\vec{g}_k^{\top} \vec{g}_k = -\|\vec{g}_k\|^2. \quad (27)$$

Esto confirma que $-\vec{g}_k$ es dirección de descenso de f en $\vec{x}_k$ (siempre que $\vec{g}_k \neq \vec{0}$).

Construcción de la interpolación. Una sola muestra adicional $\varphi(t)$ con $t > 0$ basta para fijar la parábola. Se elige $t = \min(1, \Delta_k / \|\vec{g}_k\|)$ para que el punto de muestreo $\vec{x}_k - t\vec{g}_k$ siempre caiga dentro o sobre la región de confianza: si $\|\vec{g}_k\|$ es chica, $t = 1$ es un paso unitario en $-\vec{g}_k$; si $\|\vec{g}_k\|$ es grande, $t = \Delta_k / \|\vec{g}_k\|$ coloca el punto exactamente en la frontera. Esta elección es necesaria porque fuera de la región de confianza el modelo cuadrático no se considera fiable, y muestrear f allí contradiría la filosofía del método. Con ese t , la interpolación cuadrática $I(\alpha) = a\alpha^2 + b\alpha + c$ queda determinada por las tres condiciones

$$I(0) = \varphi(0), \quad I'(0) = \varphi'(0), \quad I(t) = \varphi(t). \quad (28)$$

La primera condición fija $c = f_k$; la segunda, $b = -\|\vec{g}_k\|^2$; la tercera, $at^2 + bt + c = \varphi(t)$, que despejando a produce

$$a = \frac{\varphi(t) - f_k + t \|\vec{g}_k\|^2}{t^2}, \quad b = -\|\vec{g}_k\|^2. \quad (29)$$

Minimización de la interpolación. Si $a > 0$, I es estrictamente convexa y su mínimo se obtiene de $I'(\alpha) = 2a\alpha + b = 0$,

$$\alpha_u = -\frac{b}{2a} = \frac{\|\vec{g}_k\|^2}{2a}. \quad (30)$$

El punto de Cauchy interpolado es $\vec{p}_u = -\alpha_u \vec{g}_k$.

Relación con la fórmula clásica del Cauchy. La fórmula clásica del subproblema de región de confianza es

$$\alpha_u^{\text{clásico}} = \frac{\vec{g}_k^{\top} \vec{g}_k}{\vec{g}_k^{\top} B_k \vec{g}_k}. \quad (31)$$

A continuación se muestra que (30) y (31) son la misma fórmula bajo dos identificaciones razonables.

Paso 1: aproximar f por una cuadrática. Si f es dos veces diferenciable, una expansión de Taylor de segundo orden de f alrededor de $\vec{x}_k$ aplicada a $\vec{x}_k - \alpha \vec{g}_k$ da

$$f(\vec{x}_k - \alpha \vec{g}_k) \approx f_k + (\nabla f(\vec{x}_k))^{\top} (-\alpha \vec{g}_k) + \frac{1}{2} (-\alpha \vec{g}_k)^{\top} \nabla^2 f(\vec{x}_k) (-\alpha \vec{g}_k). \quad (32)$$

Sustituyendo $\nabla f(\vec{x}_k) = \vec{g}_k$ y simplificando los signos,

$$\varphi(\alpha) \approx f_k - \alpha \|\vec{g}_k\|^2 + \frac{1}{2} \alpha^2 \vec{g}_k^{\top} \nabla^2 f(\vec{x}_k) \vec{g}_k. \quad (33)$$

Paso 2: identificar coeficientes con la interpolación. La interpolación $I(\alpha) = a\alpha^2 + b\alpha + c$ está obligado por construcción a coincidir con φ en $\alpha = 0$, en $\alpha = t$ y en la pendiente en cero. Comparando (33) con $I(\alpha)$:

$$c = f_k, \quad b = -\|\vec{g}_k\|^2, \quad a \approx \frac{1}{2} \vec{g}_k^{\top} \nabla^2 f(\vec{x}_k) \vec{g}_k, \quad (34)$$

es decir

$$2a \approx \vec{g}_k^\top \nabla^2 f(\vec{x}_k) \vec{g}_k. \quad (35)$$

Geométricamente: $2a$ es la segunda derivada de la interpolación, e iguala a la segunda derivada de φ en $\alpha = 0$, que por la regla de la cadena es $\vec{g}_k^\top \nabla^2 f(\vec{x}_k) \vec{g}_k$.

Paso 3: identificar $\nabla^2 f$ con B_k . El método de Región de Confianza por construcción reemplaza el Hessiano verdadero $\nabla^2 f(\vec{x}_k)$ por su aproximación B_k (ec. (18)). Adoptar esta sustitución en (35) da

$$2a \approx \vec{g}_k^\top B_k \vec{g}_k. \quad (36)$$

Paso 4: comparar las dos fórmulas. Sustituyendo (36) en (30),

$$\alpha_u = \frac{\|\vec{g}_k\|^2}{2a} \approx \frac{\|\vec{g}_k\|^2}{\vec{g}_k^\top B_k \vec{g}_k} = \frac{\vec{g}_k^\top \vec{g}_k}{\vec{g}_k^\top B_k \vec{g}_k} = \alpha_u^{\text{clásico}}. \quad (37)$$

Las dos fórmulas son la misma siempre que (i) la cuadrática (33) represente bien a φ en $[0, t]$ y (ii) B_k aproxime adecuadamente a $\nabla^2 f(\vec{x}_k)$. La diferencia operativa es que $2a$ se obtiene evaluando $\varphi(t)$, mientras que $\vec{g}_k^\top B_k \vec{g}_k$ requeriría producir a B_k .

Caso $a \leq 0$: curvatura no positiva. El único caso en el que la interpolación cuadrática no produce un punto de Cauchy bien definido es cuando la parábola no abre hacia arriba, es decir $a \leq 0$. Bajo el método clásico esto no ocurre porque B_k se mantiene simétrica definida positiva por construcción y $\vec{g}_k^\top B_k \vec{g}_k > 0$ siempre. Con la interpolación, en cambio, a se estima a partir de evaluaciones de f y puede salir no positivo si f no es localmente convexa en la dirección $-\vec{g}_k$. En ese caso la parábola no tiene mínimo interior y la fórmula (30) no está definida. La respuesta es tomar

$$\vec{p}_k = -\frac{\Delta_k}{\|\vec{g}_k\|} \vec{g}_k, \quad (38)$$

es decir, el paso al borde de la región de confianza en la dirección de descenso máximo. La motivación: si el modelo cuadrático no es convexo en esa dirección, su mínimo es no acotado, y la región de confianza es lo único que impone cota al paso; saturarla en $-\vec{g}_k$ es la elección que más reduce el modelo dentro de lo factible.

Selección del paso. Cuando $a > 0$ la interpolación da un α_u bien definido y se procede con la lógica Dogleg estándar. Se calcula $\alpha_u = \|\vec{g}_k\|^2 / (2a)$, $\vec{p}_u = -\alpha_u \vec{g}_k$ y $\vec{p}_B = -H_k \vec{g}_k$. Tres casos exhaustivos según dónde caigan los dos puntos respecto a la frontera:

1. Si $\alpha_u \|\vec{g}_k\| \geq \Delta_k$ (el punto de Cauchy cae fuera de la bola): devolver el truncamiento sobre la dirección $-\vec{g}_k$, $\vec{p}_k = -(\Delta_k / \|\vec{g}_k\|) \vec{g}_k$.
2. Si $\|\vec{p}_B\| \leq \Delta_k$ (el paso de Newton cabe dentro de la bola): devolver $\vec{p}_k = \vec{p}_B$.
3. En otro caso, seguir el segmento $\vec{p}_u \rightarrow \vec{p}_B$ hasta intersectar la frontera. Con $\vec{v} := \vec{p}_B - \vec{p}_u$, se encuentra $\lambda^* \in (0, 1)$ resolviendo $\|\vec{p}_u + \lambda^* \vec{v}\|^2 = \Delta_k^2$ y se devuelve $\vec{p}_k = \vec{p}_u + \lambda^* \vec{v}$.

Evaluación de la reducción predicha. La razón ρ_k (20) del bucle externo requiere el escalar

$$\text{pred}_k := m_k(\vec{0}) - m_k(\vec{p}_k) = -\vec{g}_k^\top \vec{p}_k - \frac{1}{2} \vec{p}_k^\top B_k \vec{p}_k. \quad (39)$$

El término $\vec{p}_k^\top B_k \vec{p}_k$ es una forma cuadrática con B_k , que es justamente lo que se está evitando formar. Sin embargo, $\vec{p}_k$ siempre es combinación lineal de $\vec{p}_u$ y $\vec{p}_B$ (o proporcional a $\vec{g}_k$ en el caso del borde), de modo que basta con saber evaluar tres formas cuadráticas: $\vec{p}_u^\top B_k \vec{p}_u$, $\vec{p}_u^\top B_k \vec{p}_B$ y $\vec{p}_B^\top B_k \vec{p}_B$. Las tres se reducen a escalares disponibles usando dos hechos:

1. La interpolación cuadrática (Sección 3.2) provee la estimación $\vec{g}_k^\top B_k \vec{g}_k \approx 2a$.
2. Por definición $H_k = B_k^{-1}$, así que $B_k \vec{p}_B = B_k(-H_k \vec{g}_k) = -\vec{g}_k$.

Con esto:

$$\begin{aligned}
\vec{p}_u^\top B_k \vec{p}_u &= (-\alpha_u \vec{g}_k)^\top B_k (-\alpha_u \vec{g}_k) = \alpha_u^2 \vec{g}_k^\top B_k \vec{g}_k \approx \alpha_u^2 (2a) = \alpha_u \|\vec{g}_k\|^2, \\
\vec{p}_u^\top B_k \vec{p}_B &= (-\alpha_u \vec{g}_k)^\top (B_k \vec{p}_B) = (-\alpha_u \vec{g}_k)^\top (-\vec{g}_k) = \alpha_u \|\vec{g}_k\|^2, \\
\vec{p}_B^\top B_k \vec{p}_B &= \vec{p}_B^\top (B_k \vec{p}_B) = (-H_k \vec{g}_k)^\top (-\vec{g}_k) = \vec{g}_k^\top H_k \vec{g}_k.
\end{aligned} \tag{40}$$

(En la primera igualdad de la primera línea se usó $\alpha_u = \|\vec{g}_k\|^2 / (2a)$, de modo que $\alpha_u^2 (2a) = \alpha_u \|\vec{g}_k\|^2$.) Cada una de estas expresiones se construye en tiempo $O(n)$ a partir de cantidades ya calculadas dentro del Dogleg. La pred_k resultante para los tres casos del paso es:

Caso	$\vec{p}_k$	pred_k
Cauchy al borde	$-(\Delta_k / \ \vec{g}_k\) \vec{g}_k$	$\Delta_k \ \vec{g}_k\ - a \Delta_k^2 / \ \vec{g}_k\ ^2$
Newton dentro	$\vec{p}_B = -H_k \vec{g}_k$	$\frac{1}{2} \vec{g}_k^\top H_k \vec{g}_k$
Segmento Dogleg	$\vec{p}_u + \lambda^* (\vec{p}_B - \vec{p}_u)$	$-\vec{g}_k^\top \vec{p}_k - \frac{1}{2} \vec{p}_k^\top B_k \vec{p}_k$, expandido con las tres formas anteriores.

3.3. Aproximación con memoria limitada: L-BFGS

L-BFGS evita almacenar siquiera la matriz $H_k \in \mathbb{R}^{n \times n}$, manteniendo únicamente los m pares $(\vec{s}_i, \vec{\gamma}_i)$ más recientes en una memoria cíclica. La aproximación del Hessiano inverso queda implícitamente definida por estos pares y un escalado inicial $H_0^{(k)} = \delta_k I$ con

$$\delta_k = \frac{\langle \vec{s}_{k-1}, \vec{\gamma}_{k-1} \rangle}{\langle \vec{\gamma}_{k-1}, \vec{\gamma}_{k-1} \rangle}. \tag{41}$$

Recursión de dos ciclos. El producto $H_k \vec{g}_k = B_k^{-1} \vec{g}_k$ se calcula en tiempo $O(mn)$ sin formar matriz alguna mediante el algoritmo siguiente:

```

 $\vec{q} \leftarrow \vec{g}_k$ 
for  $i = m, m-1, \dots, 1$ :
     $\alpha_i \leftarrow \rho_i \langle \vec{s}_i, \vec{q} \rangle$ 
     $\vec{q} \leftarrow \vec{q} - \alpha_i \vec{\gamma}_i$ 
 $\vec{r} \leftarrow \delta_k \vec{q}$ 
for  $i = 1, 2, \dots, m$ :
     $\beta \leftarrow \rho_i \langle \vec{\gamma}_i, \vec{r} \rangle$ 
     $\vec{r} \leftarrow \vec{r} + (\alpha_i - \beta) \vec{s}_i$ 
return  $\vec{r}$ 

```

($\rho_i = 1 / \langle \vec{\gamma}_i, \vec{s}_i \rangle$)

Acoplamiento con el Dogleg. La recursión de dos ciclos provee el paso de Newton $\vec{p}_B = -H_k \vec{g}_k$ con una sola consulta de costo $O(mn)$. La curvatura requerida para el Cauchy proviene de la misma interpolación cuadrática definida en la Sección 3.2.

3.4. Bucle externo

```

Inicializar:  $\vec{x}_0, \Delta_0 \in (0, \Delta_{\text{máx}}), H_0 = I_n, k = 0, \vec{g}_0 = \nabla f(\vec{x}_0), f_0 = f(\vec{x}_0)$ 
mientras  $\|\vec{g}_k\|_\infty > \text{tol}$  y  $k < \text{maxIter}$ :
     $(\vec{p}_k, \text{pred}_k) \leftarrow \text{Dogleg}(\vec{g}_k, \Delta_k, H_k, f, \vec{x}_k, f_k)$ 

```

```

 $f_{k+1}^{\text{trial}} \leftarrow f(\vec{x}_k + \vec{p}_k)$ 
 $\rho_k \leftarrow (f_k - f_{k+1}^{\text{trial}}) / \text{pred}_k$ 
si  $\rho_k < \frac{1}{4}$ :  $\Delta_{k+1} \leftarrow \frac{1}{4}\Delta_k$ 
si no si  $\rho_k > \frac{3}{4}$  y  $\|\vec{p}_k\| = \Delta_k$ :  $\Delta_{k+1} \leftarrow \min(2\Delta_k, \Delta_{\text{máx}})$ 
si no:  $\Delta_{k+1} \leftarrow \Delta_k$ 
si  $\rho_k > \eta$ :
   $\vec{x}_{k+1} \leftarrow \vec{x}_k + \vec{p}_k$ ,  $f_{k+1} \leftarrow f_{k+1}^{\text{trial}}$ 
   $\vec{g}_{k+1} \leftarrow \nabla f(\vec{x}_{k+1})$ 
   $\vec{s}_k \leftarrow \vec{p}_k$ ,  $\vec{\gamma}_k \leftarrow \vec{g}_{k+1} - \vec{g}_k$ 
  si  $\vec{s}_k^\top \vec{\gamma}_k > 10^{-8}$ : actualizar  $H_{k+1}$  con (22)
  si no:  $H_{k+1} \leftarrow H_k$ 
si no:  $\vec{x}_{k+1} \leftarrow \vec{x}_k$ ,  $H_{k+1} \leftarrow H_k$ ,  $\vec{g}_{k+1} \leftarrow \vec{g}_k$ ,  $f_{k+1} \leftarrow f_k$ 
 $k \leftarrow k + 1$ 

```

Criterio de paro. El bucle termina cuando se cumple cualquiera de las dos condiciones siguientes:

$$\|\vec{g}_k\|_\infty \leq \text{tol}, \quad k \geq \text{maxIter}. \quad (42)$$

La primera corresponde a la condición de optimalidad de primer orden; la segunda es una cota dura.

4. Resultados

4.1. Configuración experimental

Para todos los experimentos se fija $k = 2$ (dimensión latente), $N = 200$ observaciones, dimensiones de entrada $d \in \{3, 5, 10, 100\}$ y un máximo de 500 iteraciones por corrida. Los datos se generan a partir de un subespacio aleatorio de dimensión k en $\mathbb{R}^d$ con perturbación gaussiana de desviación 0.05.

4.2. Datos de entrada y reconstrucción para $d = 3$

La Figura 1 muestra la nube de entrada para el caso visualizable $d = 3$. La Figura 2 compara los puntos originales con su reconstrucción y muestra el subespacio aprendido.

Nube de $N=200$ puntos en $\mathbb{R}^3$ ($d=3, k=2$)




Figura 1: Datos de entrada: 200 puntos en $\mathbb{R}^3$ generados sobre un subespacio bidimensional con ruido gaussiano.

Original X (azul) vs. reconstrucción $\hat{X}_{\text{hat}}$ (naranja)
Subespacio aprendido en verde




Figura 2: Reconstrucción $\hat{X} = DEX$ y subespacio aprendido (verde) tras 500 iteraciones del bucle externo con BFGS.

4.3. Comportamiento del bucle externo

La Figura 3 muestra la evolución de las cantidades internas del bucle externo para el caso $d = 3$: la pérdida $f(\vec{x}_k)$, la norma del gradiente $\|\vec{g}_k\|_\infty$, el radio de confianza Δ_k y la razón ρ_k . El radio se reduce de manera preponderante en las primeras iteraciones (cuando el modelo cuadrático es más impreciso) y se estabiliza posteriormente.




Figura 3: Convergencia para $d = 3$. Las líneas punteadas en el panel de ρ_k marcan los umbrales $\frac{1}{4}$ y $\frac{3}{4}$ que disparan la modificación de Δ_k .

4.4. Escalamiento en d y comparativa BFGS / L-BFGS

La Tabla 1 reporta los resultados del benchmark sobre los valores $d \in \{3, 5, 10, 100\}$. Las columnas f^* y “gap rel.” corresponden, respectivamente, a la cota de Eckart–Young (17) y al gap relativo $(f(\bar{x}^*) - f^*)/f^*$ respecto a esa cota. La columna “mem” contabiliza la memoria persistente del estado del Hessiano: n^2 flotantes para BFGS (matriz completa) y $2mn$ para L-BFGS (memoria cíclica de m pares).

d	n	método	iter	tiempo (s)	t/iter (ms)	$f(\bar{x}^*)$	f^*	gap rel.	mem
3	12	iBFGS	500	0.023	0.05	1.193e-03	1.191e-03	+1,54e-3	1.1 KB
3	12	L-BFGS $m=10$	500	0.048	0.10	1.193e-03	1.191e-03	+2,08e-3	1.9 KB
5	20	iBFGS	500	0.024	0.05	3.690e-03	3.690e-03	+1,68e-5	3.1 KB
5	20	L-BFGS $m=10$	500	0.048	0.10	3.697e-03	3.690e-03	+1,80e-3	3.1 KB
10	40	iBFGS	500	0.030	0.06	1.001e-02	1.001e-02	+6,75e-6	12.5 KB
10	40	L-BFGS $m=10$	500	0.050	0.10	1.001e-02	1.001e-02	+2,54e-4	6.2 KB
100	400	iBFGS	500	0.333	0.67	1.221e-01	1.221e-01	+2,10e-5	1250.0 KB
100	400	L-BFGS $m=10$	500	0.126	0.25	1.222e-01	1.221e-01	+5,11e-4	62.5 KB

Cuadro 1: Benchmark iBFGS (sobre H_k) vs. L-BFGS en un conjunto de valores de dimensiones de entrada. Sin invertir matrices en ningún momento y con Dogleg reformulado vía interpolación cuadrática para Cauchy. Todas las corridas usan los mismos hiperparámetros del bucle externo y la misma semilla aleatoria.




Figura 4: Escalamiento en d . Izquierda: tiempo total en escala logarítmica. Centro: memoria persistente del estado del Hessiano. Derecha: gap relativo al óptimo f^* .

4.5. Lectura de los resultados

La Tabla 1 y la Figura 4 permiten observar tres regímenes:

Calidad. En todas las dimensiones, ambos métodos convergen a una vecindad del óptimo de Eckart–Young f^* . En las dimensiones bajas e intermedias ($d = 3, 5, 10$) iBFGS satisface el criterio de optimalidad de primer orden con gap relativo entre 10^{-5} y 10^{-3} . Para $d = 100$ el gap baja a $2,1 \times 10^{-5}$, indicando que la combinación de interpolación cuadrática para Cauchy e iBFGS para H_k recupera con notable fidelidad el subespacio principal incluso con $n = 400$ parámetros.

Tiempo. A $d = 100$ iBFGS realiza la iteración completa en 0,67 ms (incluida una evaluación adicional de f por la interpolación cuadrática), y L-BFGS en 0,25 ms. La diferencia proviene de que cada operación $H_k \vec{v}$ es un producto $O(mn)$ en L-BFGS frente al producto matricial denso $O(n^2)$ de iBFGS.

Memoria. Para $d = 100$ el estado persistente del Hessiano ocupa 1 250 KB en iBFGS frente a 62,5 KB en L-BFGS (factor 20). Asintóticamente $O(n^2)$ contra $O(2mn)$ con m fijo. A cambio de ese ahorro, L-BFGS aproxima el Hessiano inverso usando sólo los m pares más recientes, lo que se traduce en gaps relativos ligeramente mayores a d pequeño.

5. Conclusiones

Se implementó un autoencoder lineal entrenado mediante un método de Región de Confianza con subproblema Dogleg, empleando los gradientes analíticos (11)–(16). El método se formuló manteniendo $H_k \approx (\nabla^2 f)^{-1}$ vía iBFGS, con el punto de Cauchy obtenido por interpolación cuadrática de f a lo largo de $-\vec{g}_k$. Se examinaron dos variantes de la inversa aproximada: matriz completa (iBFGS) y memoria limitada (L-BFGS por recursión de dos ciclos), comparadas sobre un conjunto de valores $d \in \{3, 5, 10, 100\}$.

Calidad del óptimo. Para todas las dimensiones consideradas la pérdida alcanzada se aproxima al óptimo global f^* predicho por el teorema de Eckart–Young con gaps relativos inferiores al 0,2 %. La variante iBFGS sostiene gaps del orden de 10^{-5} en $d = 5, 10, 100$, mostrando que la combinación de interpolación cuadrática para Cauchy y actualización iBFGS para H_k recupera el subespacio principal incluso a $n = 400$ parámetros.

Costo computacional. El costo por iteración está dominado por dos productos matriz–vector con H_k (uno para el paso de Newton, uno para la curvatura en la reducción predicha) y una evaluación adicional de f para el ajuste de la parábola. En iBFGS estos productos son $O(n^2)$; en L-BFGS, $O(mn)$ por la recursión de dos ciclos. La evaluación de f y ∇f es lineal en N (corridas adicionales con $N = 10^4$ no degradan la convergencia ni la calidad de la solución). Para $d = 100$ esto se traduce en 0,67 ms por iteración en iBFGS y 0,25 ms en L-BFGS. La memoria persistente del estado del Hessiano es de 1 250 KB para iBFGS contra 62,5 KB para L-BFGS, consistente con la diferencia asintótica $O(n^2)$ frente a $O(2mn)$ con m fijo.

Robustez. La implementación fue sometida a 5000 configuraciones aleatorias con $d \in \{3, 5, 10, 30\}$, ambos modos del Hessiano aproximado, semillas independientes para datos e inicialización, y rangos amplios de ruido y escala inicial. En todas las corridas se cumplen los invariantes algorítmicos: finitud numérica, reducción predicha no negativa, descenso estricto de f en cada paso aceptado, factibilidad del paso ($\|\vec{p}_k\|_2 \leq \Delta_k$) y radio en $(0, \Delta_{\text{máx}}]$. El 99 % de las corridas converge dentro del 10 % del óptimo de Eckart–Young; el 1 % restante son configuraciones de convergencia lenta (ruido alto combinado con inicialización lejos del óptimo) que tampoco violan ningún invariante.

Referencias

- [1] A. Wachtel. *Análisis Aplicado I (MAT 24430) — Notas de clase*. Instituto Tecnológico Autónomo de México, Primavera 2026.
- [2] J. Nocedal and S. J. Wright. *Numerical Optimization*, 2.^a edición. Springer Series in Operations Research, 2006.
- [3] K. B. Petersen and M. S. Pedersen. *The Matrix Cookbook*. Technical University of Denmark, version of November 2012.
- [4] J. R. Magnus and H. Neudecker. *Matrix Differential Calculus with Applications in Statistics and Econometrics*, 3.^a edición. John Wiley & Sons, 2007.